의료 영상 데이터셋을 위한 효율적인 Vision Transformer 아키텍처 개발

Development of Efficient Vision Transformer Architectures for Medical Imaging Dataset

정용훈 남현원 한동엽 강전찬 이상훈
아주대학교 소프트웨어학과

1. Motivation and Objectives

- ViT와 같은 트랜스포머 기반 모델은 우수한 성능을 보이지만 높은 계산 복잡도와 파라미터 수로 인해 경량화가 중요한 환경에서는 실용성이 떨어진다.
- LeViT 등 경량화 모델이 제안되었으나 성능을 유지하면서도 실질적인 추론 속도 개선에는 한계가 존재한다.
- 특히 의료 영상 분석에서는 신속한 의사결정이 요구되며 이로 인해 모델의 추론 속도 또한 중요한 성능 지표로 간주된다.

2. Proposed Method

2. 1 Design Principle

- LeViT을 baseline으로 불필요한 구성 요소를 제거해 추론 속도를 개선한 최적화를 진행하였다.
- 본 모델은 CNN과 Transformer의 장점을 결합한 하이브리드 구조를 바탕으로 의료 영상 분야와 같이 실시간 응답성과 높은 정확도가 동시에 요구되는 환경에 적합하도록 설계하였다.

2. 2 Stem Layer

- 초기 layer에서는 기존 LeViT과 동일하게 ResNet-18의 앞의 4개의 convolution layer를 그대로 유지.
- low level의 local feature를 효과적으로 추출하기 위한 구조로 이용.
- Stem Layer를 거쳐 입력은 3x224x224 에서 256x14x14의 feature map으로 축소.
- Transformer block에 입력될 토큰의 수를 줄이는 전처리 역할을 수행.

2. 3 1x1 Convolution

- LeViT의 세 개 stage 중 마지막 stage에 1x1 Convolution을 적용해 채널 수를 384에서 512로 증가시켰다.
- 이는 채널 간 비선형 조합을 통해 고차원 특징을 보다 정교하게 표현하면서도 파라미터 수의 증가폭은 최소화하기 위한 설계이다.
- 추가로 첫 번째와 두 번째 stage에 동일한 구조를 적용했을 때는 저차원 특징이 제대로 이루어지지 않은 문제가 발생했다.
- 세 번째 stage만 변경하여 모델의 성능을 유지하면서 전체 파라미터 수를 줄이고 추론 속도를 개선하였다.

본 연구에서는 LeViT 기반 구조의 효율성과 성능을 향상시키기 위해 다음과 같은 세 가지 구조적 개선 방안을 제안한다.

1. 각 stage의 블록 수를 기존 3개에서 2개로 축소하여 전체 모델의 연산 복잡도를 감소시켰다.
2. Attention 기반 downsampling 모듈을 Convolution 기반 downsampling 방식으로 대체함으로써 연산 효율성을 높였다.
3. LeViT의 마지막 stage에서 사용되던 Attention 연산을 제거하고, 이를 1×1 Convolution으로 대체하여 경량화를 극대화하였다.

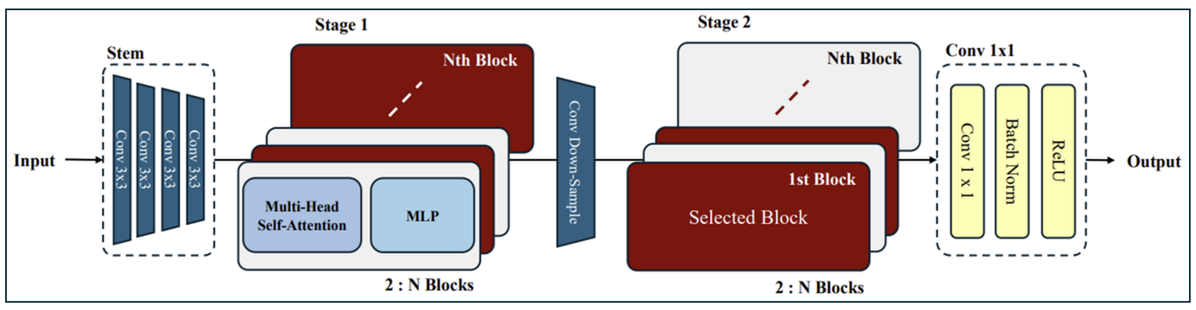

[그림 1] Overall architecture

2. 4 DownSampling 방식 변경

- 기존 LeViT은 Attention 연산을 기반으로 downsampling을 수행하여 feature map을 축소했으나 복잡한 관계 학습으로 연산량이 과도하게 늘어난다.

$$Attention_{downsample}(Q'_{S=2}, K, V) = Softmax\left(\frac{Q'_{S=2}K^T}{\sqrt{d_k}}\right)V$$

- 이를 3x3 stride 2 padding 1의 Convolution 기반 downsampling으로 대체해 계산 복잡도를 줄였다.

$$Conv_{downsample} = Conv(x, Kernel=3, Stride=2, Padding=1)$$

2. 5 stage block 수

- LeViT 모델은 각 스테이지 당 3개의 Attention 블록이 존재해, 높은 계산량으로 인해 추론 속도에 부담이 된다.
- 이 문제를 해결하기 위해 각 스테이지의 블록 수를 3개에서 2개로 줄임으로써 연산 횟수를 줄여 계산복잡성을 낮추고 효율성을 개선했다.

3. Experiments

3. 1 Experiments Settings

- Dataset : NCT-CRC-HE-100K 데이터셋 사용하였다. 총 100,000 장의 고해상도 H&E 염색된 대장암 및 정상 조직 이미지로 구성되어 있다. 데이터는 독일 NCT(National Center for Tumor Diseases) 및 민하임 의과대학 병리학 아카이브에서 수집된 86개의 Whole Slide Image(WSI)로부터 추출되었으며 개별 이미지는 224x224 해상도를 갖는다.
- Data Split : Train, Validation, Test는 7:1.5:1.5로 분할하였다.
- 모델은 Google Colab 환경에서 NVIDIA A100 GPU를 사용해 총 30 epoch 학습되었으며, learning rate는 5e-4로 설정하였다.
- Metrics : Top-1 정확도, F1 스코어, Recall, Precision을 사용하였다.

3. 2 Baseline 비교 실험

	Params	Performance		Infer Time
	(M)	Top-1	F1	Avg (ms)
Ours	4.9	99.20	99.19	6.13
ViT-Tiny	5.5	97.40	97.32	10.01
LeViT-128S	6.6	95.87	95.82	12.06
ViT	85.8	93.36	93.27	282.60
EfficientNet B0	4.0	98.97	98.95	10.49
EfficientNet B1	6.5	98.54	98.53	15.54
ResNet 50	23.5	98.73	98.75	13.29

[표 1] 베이스라인 모델 성능 비교

비교 대상 모델

Transformer 기반
- ViT
- ViT-Tiny
- LeViT-128S

CNN 기반
- ResNet-50
- EfficientNet-B0
- EfficientNet-B1

- EfficientNet-B0은 기존 연구에서 NCT-CRC-HE 데이터셋 기준 SOTA를 기록한 바 있음
- 제안 모델은 모든 평가 지표에서 경쟁력 있는 성능을 유지하면서도 EfficientNet-B0 대비 약 41.5% 빠른 추론 시간을 기록
- ViT는 큰 모델 사이즈(85.5M)로 인해 적은 에폭에서는 낮은 성능과 느린 추론 속도를 보임
- ViT-Tiny, LeViT-128은 빠른 추론 속도를 보였지만 동급 컨볼루션 모델 대비 정확도는 낮음
- 제안 모델은 Attention 구조를 CNN 기반 연산으로 대체하고 최적화된 블록 선택 방식을 적용한 하이브리드 구조 채택
- Convolution 기반 모델보다 높은 정확도, 모든 모델 중 가장 빠른 추론 속도 달성
- 결과적으로 제안 모델은 정확도와 연산 효율성 모두 향상된 구조이며, 연산 자원이 제한된 환경에서도 효과적인 솔루션이 될 수 있음

3. 3 Augmentation 실험

	Performance	
	Top-1	F1
Flip	99.08	99.06
Elastic Deformation	97.75	97.75
BSDA	98.59	98.55
Flip + Elastic Deformation	98.55	98.52
Flip + BSDA	99.05	99.03
Elastic Deformation + BSDA	96.64	96.58
Flip + Elastic Deformation + BSDA	98.59	98.58

[표 2] 제안한 모델에 대한 증강 기법별 성능 비교 결과

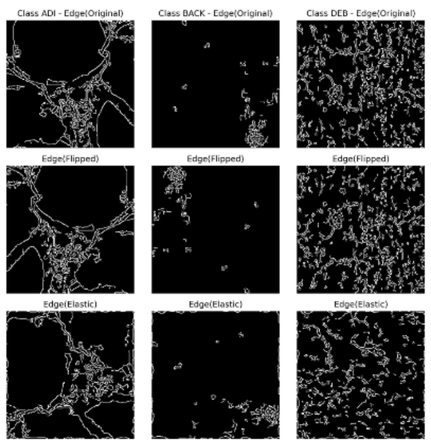

[그림 2] 원본 대비 Flipped 및 Elastic 증강 결과 비교

- 모델에 적합한 데이터 증강 기법을 탐색하고 성능과 일반화 효과를 비교 분석
- 의료 영상의 구조 보존에 초점을 맞춰 Flip, Elastic Deformation, BSDA 기법을 비교 대상으로 선정함
- Flip은 조직 구조를 손상시키지 않으면서 시각적 다양성을 부여하며, 가장 높은 성능(Top-1 Accuracy 99.08%, F1 Score 99.06%)을 기록함
- BSDA는 중간 feature vector에 확률적으로 증강을 적용하며, 단독 또는 Flip과 병행 시에도 우수한 일반화 성능을 유지함
- Elastic Deformation은 조직 경계를 왜곡하여 성능을 저하시켰으며 Canny edge map 분석에서도 구조 왜곡이 시각적으로 확인됨
- 세 기법을 모두 조합할 경우 성능이 감소(Top-1 Accuracy 98.59%)하였고 이는 데이터 분포의 과도한 왜곡 때문으로 해석됨
- NCT-CRC-HE-100K 데이터는 색상 정규화와 크기 통일 등의 전처리를 이미 거쳐 구조적 일관성이 높으므로 단순한 Flip만으로도 충분한 효과를 보임

4. Result & Conclusion

본 연구에서는 비전 트랜스포머의 높은 시간 복잡도와 느린 추론 속도를 개선하기 위해 LeViT 기반 구조에 다양한 경량화 기법을 적용한 모델을 제안하였다. 어텐션 블록 수를 줄이고 어텐션 기반 다운샘플링을 컨볼루션 기반 연산으로 대체하며 1×1 Convolution을 도입함으로써 LeViT 대비 추론 속도를 49.1% 단축하고 정확도를 3.5% 향상시켰다. 또한, 적절한 데이터 증강 기법을 통해 최대 99.08%의 정확도를 달성하며 제안 모델의 성능을 효과적으로 극대화할 수 있음을 확인하였다. 이러한 정확도와 연산 효율성의 개선은 의료 영상 분석, 병리 이미지 분류, 실시간 임상 분석 등과 같이 제한된 연산 자원과 빠른 응답이 요구되는 환경에서 제안 모델의 높은 실용 가능성을 보여준다.