# 의료 영상 데이터셋을 위한 효율적인 Vision Transformer 아키텍처 개발*

정용훈[0], 남현원, 한동엽, 강전찬, 이상훈
아주대학교 소프트웨어학과
younghune135@ajou.ac.kr, hwnam1129@ajou.ac.kr, handy724@ajou.ac.kr, djc08072@ajou.ac.kr, sanghoonlee@ajou.ac.kr

# Development of Efficient Vision Transformer Architectures for Medical Imaging Dataset

Yonghun Jeong[0], HyunWon Nam, Dongyeob Han, Jeonchan Kang, Sanghoon Lee
Department of Software, Ajou University
younghune135@ajou.ac.kr, hwnam1129@ajou.ac.kr, handy724@ajou.ac.kr, djc08072@ajou.ac.kr, sanghoonlee@ajou.ac.kr

**요 약**

기존 Transformer 기반 모델들은 좋은 성능을 보이나 추론 시간이 느린 문제가 있다. 특히 빠른 추론 시간이 요구되는 의료 도메인에서 Transformer 기반 모델을 적용하기 어렵다. 본 연구에서는 이를 해결하고자 컨볼루션과 Transformer를 결합한 하이브리드 구조를 적용하여 추론 시간을 개선하였고 추가적인 데이터 증강 기법을 활용해 성능을 유지하는 모델을 제안한다. 해당 모델은 암 조직 데이터셋(NCT-CRC-HE 100K)에서 SOTA에 비해 정확도는 유지하면서 추론 시간을 41.5% 개선하였다.

## 1. 서 론

최근 컴퓨터 비전 분야에서는 ViT[1]와 같은 트랜스포머 기반의 모델들이 좋은 성능을 보여주고 있다.하지만, 높은 계산 복잡도, 많은 파라미터 등, 경량화가 중요한 분야에서는 실용성이 떨어지는 경우가 있다. ResNet[2]과 같은 기존 CNN 기반 모델이 사용되거나 LeViT[3]과 같은 경량화 트랜스포머 모델이 제안되었다. 하지만 여전히 성능을 유지하면서 추론 시간을 효과적으로 개선하는 측면에서는 아직 개선의 여지가 있다. 위의 모델 모두 ViT의 단점을 개선한 모델이긴 하지만 여전히 추론 시간을 효과적으로 개선하기에는 한계가 존재했다.

특히 의료 분야에서는 질병 진단이나 영상 분류 과정에서 실시간으로 신속하게 결과를 제시해야 하는 경우가 많은데, 이 때 모델의 성능 뿐만 아니라 추론 속도도 중요한 평가지표로 작용한다. 이러한 문제들을 해결하기 위해 모델의 경량화 및 추론 속도 개선과 함께 데이터 증강 기법을 통해 성능 또한 유지하고자 하는 연구가 진행되고 있다. [4]

의료 분야의 실험에서 적용하고 있는 데이터 증강 방식으로는 이미지 회전, 자르기, 밝기 조절과 같은 일반적인 방법이 활용되고 있다. 최근에는 BSDA(Bayesian Random Semantic Data Augmentation)[5]과 같은 방법이 제안되면서 모델의 일반화 성능을 개선하는 데에 쓰이고 있다.

본 연구에서는 LeViT 모델을 기반으로 다양한 모델의 경량화 방식을 도입하고, Data augmentation 방식을 활용하여 추론 시간 개선과 모델의 일반화 성능을 향상시킬 수 있는 모델을 탐구해보고자 한다.

## 2. 제안 방식

본 연구에서는 baseline으로 LeViT 모델을 이용했다. LeViT의 경우 ViT의 느린 추론 시간이라는 단점을 극복하기 위해 등장한 트랜스포머 기반 모델로, CNN을 활용해서 지역적 특성을 잡아내면서 추론시간까지 개선되는 결과를 보였다. LeViT은 여러 attention 계층을 가지며, attention 기반 downsampling을 수행한다. LeViT의 구성요소를 수정하여 추론 시간을 개선하면서도 성능을 유지할 수 있는 방법을 연구했다.

### 2.1 stage block 수

LeViT 모델에서는 각 스테이지에 3개의 Attention 블록이 존재하여 계산량이 많아 추론 속도에 부담이 되는 문제가 있었다. 이러한 문제를 해결하기 위해 각 스테이지의 Attention 블록 수를 기존 3개에서 2개로 줄이는 방식을 도입하여, Attention 연산의 반복 횟수를 줄여 계산 복잡성을 낮추고 효율성을 개선하였다. 이와 같은 구조적 개선을 통해 모델의 추론 시간을 단축하면서도 기존 모델과 유사한 성능을 유지할 수 있었다.

*이 논문은 2025년도 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의 지원을 받아 수행된 연구 결과임 (No.2022-0-01077, SW중심대학사업, No.RS-2025-02283048, 휴먼-AI 동반자 시대를 위한 AGI: 신뢰성·윤리성·적응성을 갖춘 차세대 범용 인공지능 개발)

| | Params | Performance | | Infer Time |
|---|---|---|---|---|
| | (M) | Top-1 | F1 | Avg (ms) |
| Ours | 4.9 | 99.08 | 99.06 | 6.13 |
| ViT-Tiny | 5.5 | 97.40 | 97.32 | 10.01 |
| LeViT-128S | 6.6 | 95.87 | 95.82 | 12.06 |
| ViT | 85.8 | 93.36 | 93.27 | 282.60 |
| EfficientNet B0 | 4.0 | 98.97 | 98.95 | 10.49 |
| EfficientNet B1 | 6.5 | 98.54 | 98.53 | 15.54 |
| ResNet 50 | 23.5 | 98.73 | 98.75 | 13.29 |

표1. 베이스라인 모델 성능 비교

2.2 Downsampling 방식 변경

기존 LeViT 모델은 Attention 기반의 downsampling을 진행한다. 이 과정은 feature map을 압축하는 역할을 하는데 attention 연산을 사용한다.

$$Attention_{downsample}(Q'_{S=2}, K, V) = Softmax(\frac{Q'_{S=2}K^T}{\sqrt{d_k}})V$$

이는 downsampling 과정에서의 복잡한 관계 학습이 오히려 계산량의 증가로 비효율적일 것이라고 판단했고, 이를 컨볼루션 downsampling 방법으로 변경했다.

$$Conv_{downsample} = Conv(x, Kernel = 3, Stride = 2, Padding = 1)$$

해당 변경으로 Attention 기반 downsampling에 비해 연산량을 줄일 수 있고, 그 결과 성능은 유지한 채 추론 시간은 개선되는 결과를 얻었다.

2.3 1x1 컨볼루션

LeViT에서는 총 3개의 stage가 존재하는데, 이 중 마지막 stage를 1x1 컨볼루션을 활용하여 채널 수를 384에서 512로 증가 시켰다. 이를 통해 파라미터 수의 증가폭을 줄인다. 그와 동시에 채널 간의 비선형적 조합을 통해 고차원 특징을 보다 정교하게 표현하게 해주었다. 첫번째와 두 번째 layer를 1x1 컨볼루션으로 변경한 결과 저차원 특징이 제대로 학습이 되지 않았다. 따라서 세 번째 stage를 변경하여 모델의 성능을 최대한 유지하면서 전체 모델의 파라미터 수를 효과적으로 줄이고 이와 동시에 추론 시간을 개선했다.

## 3. 실험결과

3.1 Baseline 비교 실험

성능 비교를 위해 기본 모델로 ViT, ViT-Tiny, LeViT-128을 사용하였으며, 추가적으로 ResNet-50과 EfficientNet-B0, B1도 포함하였다. 특히 EfficientNet-B0[6]은 기존 연구에서 본 데이터셋(NCT-CRC-HE) 상에서 SOTA(State-Of-The-Art)를 달성한 바 있다.[4]

| | Performance | |
|---|---|---|
| | Top-1 | F1 |
| **Flip** | **99.08** | **99.06** |
| Elastic Deformation | 97.75 | 97.75 |
| BSDA | 98.59 | 98.55 |
| Flip + Elastic Deformation | 98.55 | 98.52 |
| Flip + BSDA | 99.05 | 99.03 |
| Elastic Deformation + BSDA | 96.64 | 96.58 |
| Flip + Elastic Deformation + BSDA | 98.59 | 98.58 |

표2. 제안한 모델에 대한 증강 기법별 성능 비교 결과

표1의 결과를 보면, 제안된 모델은 모든 평가 지표에서 경쟁력 있는 성능을 유지하면서도 EfficientNet-B0 대비 추론 시간을 약 41.5% 단축하였다. 이러한 효율성은 최적화된 블록 선택 방식과 기존의 Attention 구조를 CNN 기반 연산으로 대체한 설계에서 비롯된다.

전반적으로 트랜스포머 기반 모델보다 컨볼루션 기반 모델들이 본 태스크에서는 더 우수한 성능을 보이는 경향이 있다. 예를 들어, ViT는 85.5M에 달하는 큰 모델 사이즈로 인해 적은 학습 에폭에서는 낮은 성능과 느린 추론 속도를 나타냈다. ViT-Tiny와 LeViT-128은 비교적 빠른 추론 시간을 보였으나, 유사한 크기의 컨볼루션 기반 모델들과 비교했을 때 성능은 다소 낮았다.

반면, 제안된 모델은 트랜스포머와 컨볼루션의 장점을 결합한 하이브리드 구조를 채택함으로써, 컨볼루션 기반 모델들보다 높은 성능을 달성하는 동시에, 모든 비교 모델 중 가장 빠른 추론 속도를 기록하였다.

이러한 결과는 제안된 모델이 연산 효율성과 정확도 측면에서 모두 향상된 설계를 바탕으로, 특히 연산 자원이 제한된 환경에서도 매우 효과적인 솔루션이 될 수 있음을 보여준다.

3.2 Augmentation 실험

기존 EfficientNet-B0에 대한 augmentation 연구에서는 NCT-CRC-HE-100K로 학습하고 NCT-CRC-HE-7K로 검증하는 과정에서 RandAugment, Color Jitter, Stain Normalization 등의 기법을 적용하여 모델의 일반화 성능을 향상시켰다.

제안된 모델에 적합한 증강 기법을 탐색하기 위해 elastic deformation, BSDA, 그리고 기본적인 flip에 대한 실험을 진행하였다. Elastic deformation은 조직 구조의 유연한 변형을 모사하여 구조적 일반화를 유도하는 데 초점을 맞췄다. BSDA는 입력 이미지 대신 신경망에서 추출한 특징 벡터를 확률적인 방식으로 증강을 수행하는 데에 맞췄다. 이는 의료 이미지 데이터에서 증강기법을 적용할 때 최대한 의미를 보존하기 위한 방법이다.

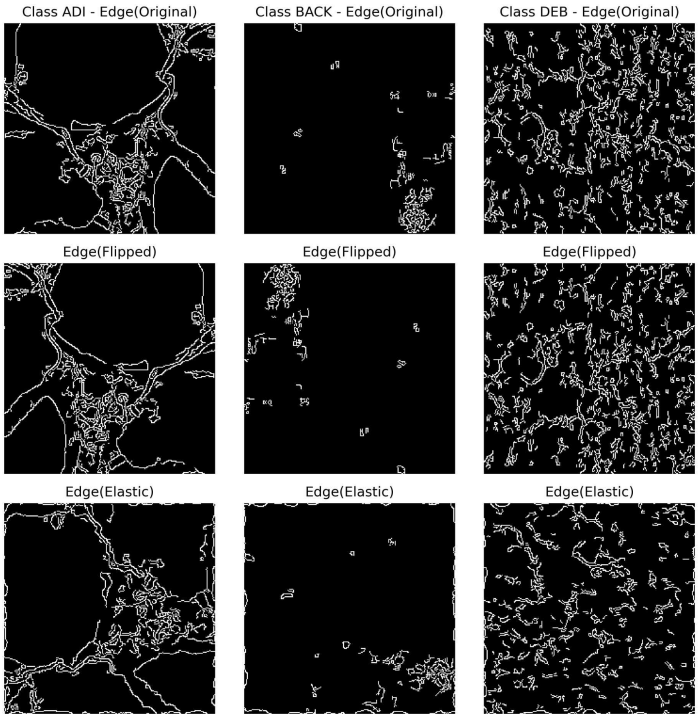

그림1. 원본 대비 Flipped 및 Elastic 증강 결과 비교

Flip은 가장 기본적인 형태의 공간 변형 기법으로, 좌우 반전과 상하 반전을 통해 데이터 다양성을 확보하였다. 표 2는 Augmentation 기법별 성능을 비교한 결과이다. Flip 기법을 적용했을 때 가장 높은 성능(Top-1 Accuracy 99.08%, F1 Score 99.06%)을 기록하였다. Flip 기법만 사용하는 경우, 모델의 일반화 성능을 극대화했음을 확인할 수 있었다. 반면, 세 가지 기법을 모두 조합한 경우에는 오히려 성능이 감소(Top-1: 98.59%)하여, 과도한 증강으로 인한 데이터 분포 왜곡가능성을 보여준다. 이는 NCT-CRC-HE-100K 데이터셋이 이미 색상 정규화(Macenko 방법)와 크기 통일 등 여러 형태의 전처리를 거친 상태로 이미지 간의 색상과 구조적 일관성이 높은 것이 특징이기 때문이다. 따라서 단순한 좌우 또는 상하 반전과 같은 Flip 기법은 원본 데이터의 구조를 유지하면서 시각적 다양성만 부여하여 학습에 긍정적인 효과를 준 반면 Elastic Deformation과 같은 기법은 이미지의 경계 정보를 왜곡시켜 오히려 모델의 학습을 방해한 것으로 보인다. 그림1은 Canny edge map을 통해 Flip, Elastic 증강 이미지의 경계선을 비교해본 결과이다. Elastic 기법을 적용한 경우 이미지 외곽에서 비정상적인 왜곡 패턴이나 경계선의 지글거림이 관찰되었으며 이는 원본의 조직학적 구조가 보존되지 않았음을 시각적으로 확인할 수 있다.

이러한 결과는 의료 이미지에 대한 증강 기법 설계 시, 데이터의 의미 보존과 구조적 유사성 유지가 성능에 중요한 영향을 미친다는 것을 시사한다.

## 4. 결론

본 연구에서는 비전 트랜스포머의 높은 시간 복잡도와 추론 속도를 개선하고자, 기존에 제안되었던 LeViT을 기반으로 개선 방안들을 적용한 모델을 제안한다. Stage의 어텐션 블록 수 감소, 어텐션 기반 downsampling에서 컨볼루션 기반 downsampling으로의 대체, 1x1 컨볼루션의 도입으로 LeViT보다 추론 속도가 49.1% 감소하였고 정확도는 3.5% 증가하였다. 또한 다양한 데이터 증강 기법을 통해 성능을 99.08%까지 높임으로써, 제안하는 모델이 적절한 증강 기법을 통하여 성능을 효과적으로 극대화할 수 있음을 보였다. 이러한 성능 및 속도 개선 특성을 바탕으로, 제안하는 모델은 의료 영상 분석, 병리 이미지 분류, 또는 실시간 분석이 요구되는 임상 환경 등에서 활용 가능성이 높다. 향후 연구로는 네트워크 경량화를 위한 구조적 프루닝, 효율적인 Attention 대체 모듈 도입을 추가적으로 고려될 수 있다.

## 참고 문헌

[1] Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterhiner, T., Dehghani, M., Minderer, M., Heigold, G., Gelly, S., Uszkoreit, J., Houlsby, N., "An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale", International Conference on Learning Representations, 2021.

[2] He, K., Zhang, X., Ren, S., Sun, J., "Deep Residual Learning for Image Recognition", in Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, pp. 770-778, 2016.

[3] Graham, B., El-Nouby, A., Touvron, H., Stock, P., Joulin, A., Jegou, H., Douze, M., "LeViT: A vision transformer in convnet's clothing for faster inference", in Proceedings of the IEEE/CVF International Conference on Computer Vision, pp. 12259-12269, 2021.

[4]Ignatov, A., Malivenko., G., "NCT-CRC-HE: Not all histopathological datasets are equally useful", https://arxiv.org/abs/2409.11546, 2024.

[5] Zhu, Y., Cai, X., Wang, X., Chen, X., Fu, Z., Yao, Y., "BSDA: Bayesian Random Semantic Data Augmentation for Medical Image Classification", Sensors 24 (23), 7511, 2024.

[6] Tan, M., Le, Q. V., "EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks", International Conference on Machine Learning, pp. 6105-6114, 2019